



Pipeline de Ciência de Dados para Análise de DRX

Integrando Python e Machine Learning na Difração de Raios X


PhD Anuar J Mincache

Motivação

Por que integrar Ciência de Dados à Análise de DRX?

- DRX gera dados complexos,
- ricos em informação estrutural.
- Interpretação manual é lenta e sujeita a erros.
- Python e ML permitem automatizar e prever propriedades. Vamos construir um pipeline completo do dado à predição.

O que é um Pipeline em Ciência de Dados



Por que usar Pipelines em DRX

DRX produz grandes quantidades de dados experimentais (.xy, .csv, .txt).

Necessário integrar etapas de:

Normalização e filtragem de ruído

Identificação de picos e parâmetros de rede

Correlação com propriedades físicas

Pipelines permitem comparar amostras, prever parâmetros e criar bases sintéticas.

Fundamentos de Difração de Raios X

Interação da radiação X com planos cristalinos →
Lei de Bragg


Picos → planos cristalográficos (hkl)

Análise permite:

Identificar fases

Calcular parâmetros de rede

Observar tensões, tamanho de cristalito,
microstrain


$$n\lambda = 2d \sin \theta$$

- Leitura no Python (pandas)

```
python
```

```
import pandas as pd  
df = pd.read_csv("amostra.csv")  
display(df.head())
```

Organização dos Dados

- Arquivos experimentais: .csv, .xy, .txt
- Estrutura típica:

```
import matplotlib.pyplot as plt
plt.plot(df['2theta'], df['intensity'])
plt.xlabel("2θ (degrees)")
plt.ylabel("Intensity (a.u.)")
plt.title("XRD Pattern")
plt.show()
```

Visualização de Padrões de DRX

Pré- processamento dos Dados

Normalização: ajustar amplitude (ex: min-max scaling).

Suavização: remoção de ruído (média móvel, Savitzky–Golay).

Interpolação: alinhar pontos de 2θ .

Resultado: dados limpos e comparáveis entre amostras.

Extração de Características

Localização e intensidade dos picos principais.

Cálculo de:

Posição (2θ)

Intensidade máxima

Largura (FWHM)

Geração de Dados Sintéticos

Importância de bases maiores para ML.

Estratégias:

Adicionar ruído controlado.

Interpolar entre amostras reais.

Simular picos via funções gaussianas.

Permite ampliar diversidade sem novos experimentos.

Ciência de Dados Aplicada a DRX

Data Science = integração de:

Estatística

Programação

Conhecimento físico-químico do material

Aplicações:

Correlação entre dopagem × estrutura

Classificação de fases cristalinas

Predição de parâmetros estruturais (a, c, strain...)

Introdução ao Machine Learning

ML aprende padrões a partir dos dados experimentais.

Dois tipos principais:

Supervisionado: predição (regressão ou classificação).

Não supervisionado: agrupamento, redução de dimensionalidade.

Aqui: **Regressão supervisionada.**


```
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score, mean_squared_error

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2)
model = LinearRegression().fit(X_train, y_train)
y_pred = model.predict(X_test)
```

Regressão com Scikit-learn

- Exemplo: prever **parâmetro de rede a** a partir das intensidades dos picos.
- Etapas:
 - 1.Separar dados em treino e teste
 - 2.Escolher modelo (LinearRegression, RandomForest, etc.)
 - 3.Treinar o modelo
 - 4.Avaliar com MSE e R^2

Avaliação e Visualização dos Resultados

```
plt.scatter(y_test, y_pred)
plt.xlabel("Measured values")
plt.ylabel("Predicted values")
plt.title(f" $R^2$  = {r2_score(y_test, y_pred):.3f}")
plt.show()
```

- **Métricas:**
 - RMSE (Root Mean Squared Error)
 - R^2 (Coeficiente de determinação)
- Visualize o quão bem o modelo prevê parâmetros estruturais.

Integração Completa: Pipeline Automático

Importar dados (.csv, .xy)

Normalizar e suavizar

Extrair picos e características

Treinar modelo de regressão

Avaliar e visualizar resultados

Exportar modelo treinado

Discussão e Perspectivas

Combinar DRX + ML → novos insights em materiais.

Possibilidades:

Refinamento Rietveld com IA

Predição de microstrain e tamanho de cristalito

Modelos físicos-informados (Physics-Informed ML)

Desafios: base de dados, interpretação física, validação experimental.

Conclusões

Pipelines unem **ciência de dados e física de materiais**.

Automatizam análises de DRX com reprodutibilidade.

ML permite prever parâmetros estruturais com rapidez.

Próximo passo: integrar **Deep Learning** e **dados multitécnicas**

Obrigado pela sua
atenção

